CS 491/492 BITIRME PROJESI TEKNIK MIMARI VE FIZIBILITE RAPORU

Kurumsal Yapılandırılmamış Veri İşleme (IDP), Data Lakehouse ve GenBI Karar Destek Platformu

Çok İştirakli Holdingler ve Finans Kurumları İçin Uçtan Uca Veri Mühendisliği ve Yapay Zeka Mimarisi

Proje Ekibi:	Bilkent CS 491/492 Ekibi (5 Kişi)	**Mimari Yaklaşım:**	Medallion Lakehouse + Hybr
Hedef Sektör:	Holdingler, Bankalar, Büyük Kurumlar	**Doküman Amacı:**	Ekip İçi Hizalanma & Saha H

1. Problem Tanımı ve Kurumsal Bağlam

Holdinglerde ve finans kurumlarında veri ekosistemi yüksek derecede parçalı (fragmented) ve heterojen bir yapıdadır. Grup şirketlerinden biri kurumsal kaynak planlaması için SAP, diğeri Oracle veya Microsoft Dynamics kullanırken; hukuk, satın alma, denetim ve operasyon birimleri hala Excel tabloları, taranmış PDF faturalar, serbest formatlı tedarikçi sözleşmeleri ve e-postalar üzerinden süreç yürütmektedir. Kurumsal verilerin yaklaşık **%80'i bu yapılandırılmamış (unstructured) veya yarı-yapısal (semi-structured)** formatlarda kilitli kalmaktadır.

Holding üst yönetimi (C-Level) ise tüm iştiraklerin tedarikçi riskini, sözleşme cezalarını, denetim bulgularını ve konsolide nakit akışını tek bir merkezi ekranda görmek ve sorgulamak istemektedir. Bu projenin amacı; farklı iştiraklerden gelen dağınık verileri otonom olarak ayrıştıran, standartlaştıran, tekilleştiren ve doğal dil ile sorgulanabilir bir İş Zekası (BI) katmanına dönüştüren uçtan uca bir veri platformu geliştirmektir.

Kurumsal Pitch / Yönetici Özeti (Saha Görüşmeleri İçin)

*"Holding iştiraklerinden gelen çok kaynaklı ve dağınık veriler için yerel Büyük Dil Modelleri (On-Premise LLM) destekli bir **Unstructured Data ETL (IDP)** hattı ve bunun üzerinde çalışan, veri soykütüğü (lineage) izlenebilir bir **Data Lakehouse & GenBI** karar destek platformu geliştiriyoruz."*

2. Endüstriyel Terminoloji ve Sistem İsimlendirmesi

Kurumsal paydaşlarla (CTO, CDO, Kurumsal Mimarlar, BI Direktörleri) yapılacak gereksinim analizi (Requirement Engineering) toplantılarında sistemin katmanları aşağıdaki endüstri standartlarıyla ifade edilmelidir:

- **IDP (Intelligent Document Processing) & Unstructured Data ETL:** Taranmış PDF, e-posta, Word, ses kaydı veya görsel gibi yapılandırılmamış verileri alıp OCR, görsel yerleşim analizi (Layout Parsing) ve LLM kullanarak katı şemaya uygun yapısal tablolara (JSON/SQL) dönüştüren ilk işleme katmanıdır.
- **Data Lakehouse Mimarisi:** Ham dosyaların tutulduğu *Data Lake* (Veri Gölü) esnekliği ile İş Zekası (BI) için gereken ACID işlemli *Data Warehouse* (Veri Ambarı) performansını tek bir mimaride birleştiren modern veri yaklaşımıdır.
- **MDM (Master Data Management) & Entity Resolution:** Farklı grup şirketlerinden gelen aynı müşteri, tedarikçi veya ürün kayıtlarının (farklı isim veya kodlarla yazılsalar dahi) tekilleştirilerek tek bir "Altın Kayıt" (*Golden Record*) altında birleştirilmesidir.
- **GenBI (Generative Business Intelligence):** Klasik statik dashboard'ların ötesine geçerek, yöneticilerin sisteme doğal dille karmaşık sorular sorup hem ilişkisel SQL tablolarından hem de PDF dokümanların

metinlerinden birleşik ve kanıtlı yanıt alabildiği yeni nesil analitik katmanıdır.

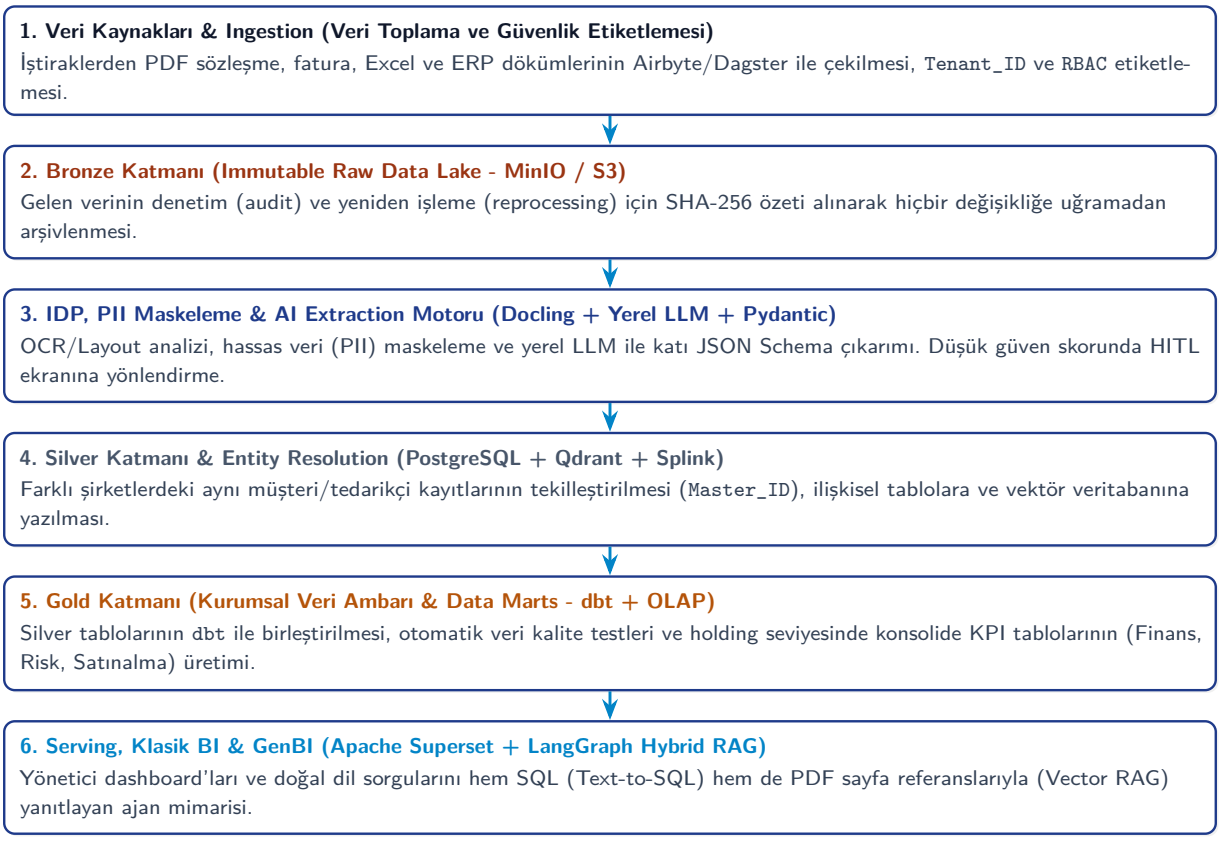
3. Önerilen Teknoloji Yığını (Modern & AI-Native Stack)

Kurumsal dünyada yüksek lisans maliyetli kapalı sistemler (Databricks, Snowflake, Informatica) yaygın olsa da, 5 kişilik mühendislik ekibi için esnek, sıfır lisans maliyetli ve kurum içi (On-Premise / Air-Gapped) kuruluma uygun açık kaynaklı **Modern Data Stack (MDS)** seçilmiştir:

Mimari Katman	Kurumsal Muadili	Proje Tech Stack'i	Temel Mühendislik Görevi
1. Orkestrasyon & Ingestion	AWS Glue, Azure Data Factory, MuleSoft	**Dagster** veya **Apache Airflow** + **Airbyte**	Farklı şirketlerden gelen verileri zamanlanmış görevlerle (cron/event) çekmek, hata yönetimi ve veri soykütüğünü yönetmek.
2. Depolama (Lakehouse)	Snowflake, AWS S3 + Redshift	**MinIO** (S3 uyumlu) + **Apache Iceberg** / **PostgreSQL**	Ham dosyaları (PDF, Excel) nesne depolamada, çıkarılan yapısal verileri ise ilişkisel/analitik tablolarda versiyonlayarak saklamak.
3. Unstructured Parsing & OCR	AWS Textract, Azure Doc Intelligence	**Docling** (IBM), **Unstructured.io**, **PaddleOCR**	Karmaşık PDF'lerdeki tabloları, başlıkları, sayfa koordinatlarını (bounding box) ve çok sütunlu metinleri ayrıştırmak.
4. AI Bilgi Çıkarımı (Extraction)	OpenAI Enterprise, AWS Bedrock	**vLLM / Ollama** (Llama 3 / Qwen) + **Instructor / Pydantic**	Metin içinden katı şema (JSON Schema) kurallarına uygun yapısal veri çıkarmak (VKN, tutar, vade, ceza maddesi vb.).
5. Dönüşüm, MDM & Vektör DB	Databricks, Informatica MDM, Pinecone	**dbt (Data Build Tool)** + **Qdrant** / **pgvector** + **Splink**	Veriyi SQL ile temizleyip BI'a hazır hale getirmek (dbt), tekilleştirmek (Splink) ve semantik arama için vektörlemek (Qdrant).
6. BI, Sunum & Ajan Mimarisi	PowerBI, Tableau, Microsoft Copilot	**Apache Superset** / **Metabase** + **LangGraph** + **Next.js** / **FastAPI**	Klasik KPI dashboard'ları için Superset; doğal dille sorgulama (Text-to-SQL + Hybrid RAG) ve HITL onay ekranı için özel arayüz.

4. Uçtan Uca Sistem İşleyişi (Medallion Architecture)

Endüstride büyük veri ve analitik boru hatlarının altın standardı **Medallion Architecture (Bronze → Silver → Gold)** yaklaşımıdır. Aşağıdaki mimari akış, verinin holding iştiraklerinden çıkıp yönetici ekranına ulaşana kadar geçtiği 6 temel aşamayı tanımlar.



5. Somut Uçtan Uca Veri Akışı Senaryosu (Concrete Walkthrough)

Sistemin nasıl çalıştığını somutlaştırmak için holdingin iki farklı iştirakinden gelen verilerin işlenme örneği aşağıda modellenmiştir:

- **Girdi 1 (Enerji İştiraki - Taranmış PDF Sözleşme):** *"...işbu sözleşme **Arçelik Pazarlama A.Ş.** (VKN: 1234567890) ile imzalanmış olup, gecikme durumunda günlük **%0.5 ceza** uygulanır. Toplam bedel **250.000 USD**'dir..."*
- **Girdi 2 (Lojistik İştiraki - Excel Fatura Tablosu):** Satır verisi: `Firma: ARÇELİK AŞ | Vergi_No: 1234567890 | Tutar: 8.500.000 TL | Durum: Ödenmedi`.

Adım 3 & 4'te (IDP ve Silver Katmanı) Üretilen Standart JSON ve Tekilleştirme Çıktısı:

```
{
  "extraction_id": "EXT-2026-9841",
  "source_tenant": "HOLDING_ENERJI_AS",
  "master_entity_id": "GLD_ENT_0042",        # "Arçelik Pazarlama" ve "ARÇELİK AŞ" VKN/Fuzzy
      ile birleşti
  "canonical_name": "Arçelik A.Ş.",
  "financials": {
    "original_amount": 250000.0,
    "original_currency": "USD",
    "normalized_amount_try": 8550000.0,      # Merkez Bankası kuru ile normalize edildi
    "penalty_rate_daily": 0.005
  },
```

```
  "lineage_metadata": {                    # Denetim (Audit) için Veri Soykütüğü
    "source_file_uri": "s3://bronze-bucket/enerji/sozlesme_2026_44.pdf",
    "page_number": 4,
    "bounding_box": [120.5, 450.2, 510.0, 495.8],
    "llm_confidence_score": 0.94           # > 0.85 olduğu için HITL onayına gerek kalmadan
        geçti
  }
}
```

Listing 1: Docling + Instructor (Pydantic) + Entity Resolution Sonrası Üretilen Yapısal Veri

Bu çıktı sayesinde holding yöneticisi Gold katmanında **Arçelik A.Ş.** için hem Lojistik hem Enerji şirketindeki toplam riski (`8.5M TL + 8.55M TL = 17.05M TL`) tek satırda görebilir ve ilgili PDF sayfasına doğrudan tıklayarak gidebilir.

6. Kurumsal Veri Yönetişimi, Güvenlik ve İzlenebilirlik

Bankalar ve holdinglerle yapılacak görüşmelerde projenin kurumsal standartlara (Enterprise-Grade) uygunluğunu kanıtlayacak dört kritik mimari özellik şunlardır:

1. **Veri Soykütüğü ve Kanıtlanabilirlik (Data Lineage & Citation):** Finansal raporlamada bir sayının nereden geldiği hayati önem taşır. Sistemde çıkarılan her veri hücresi, kaynak PDF'in S3 adresi, sayfa numarası ve koordinatları (`bounding_box`) ile birlikte kaydedilir. Yönetici BI ekranında bir anomali gördüğünde tek tıkla orijinal doküman üzerindeki ilgili paragrafı sarı ile işaretlenmiş olarak görüntüler.

2. **Çok Kiracılı Yetkilendirme (Multi-Tenancy & Row-Level Security):** Holding bünyesindeki A şirketinin analisti sisteme girdiğinde sadece A şirketine ait verileri görebilirken, Holding CEO'su tüm şirketlerin konsolide verisini görebilir. Bu yapı PostgreSQL *Row-Level Security (RLS)* ve Qdrant metadata filtreleri (`tenant_id`) ile garanti altına alınır.

3. **KVKK / BDDK Uyumu ve PII Maskeleme:** Dokümanlar LLM'e gönderilmeden önce `Microsoft Presidio` veya yerel Regex/NER filtrelerinden geçirilerek TC Kimlik No, kredi kartı ve şahıs telefon numaraları gibi Kişisel Veriler (PII) maskelenir veya sistem tamamen kurum içi (On-Premise) GPU sunucularında çalıştırılır.

4. **Human-in-the-Loop (HITL - İnsan Onay Mekanizması):** OCR okunabilirliğinin düşük olduğu veya LLM'in şema çıkarımında kararsız kaldığı durumlarda (`confidence < 0.85`), kayıt karantinaya alınır ve arayüzdeki "Onay Bekleyen Dokümanlar" kuyruğuna düşer. Uzman düzeltmesi aynı zamanda sistemin gelecekteki örnekleri (Few-Shot Prompting) için geri besleme olarak kullanılır.

7. Başarı Metrikleri ve Değerlendirme (CS 491/492 Jüri Kriterleri)

Bitirme projesinin akademik ve endüstriyel başarısını kanıtlamak için sistemin her katmanı nicel (quantitative) metriklerle test edilecektir:

Test Edilen Katman	Ölçüm Metriği	Hedef Başarı Kriteri ve Açıklama
1. OCR & Layout Parsing	CER / WER & TEDS (Table Extraction Score)	Karmaşık PDF tablolarının yapısal olarak doğru çıkarılma oranında **TEDS > %90** başarımı.
2. LLM JSON Çıkarımı	Schema Validity & Field-Level F_1 Score	Pydantic şemasına %100 uyum (Sıfır sintaks hatası) ve alan bazlı veri doğruluğunda $F_1 > 0.92$.
3. Entity Resolution (MDM)	Precision, Recall & F_1	Farklı yazılmış şirket/müşteri isimlerini yanlış birleştirmeden (Yüksek Precision) tekilleştirmede $F_1 > 0.90$.
4. GenBI (Hybrid RAG & SQL)	Execution Accuracy (EX) & RAGAS Faithfulness	Üretilen SQL sorgularının doğru çalışma oranı (**>%85**) ve üretilen metin yanıtlarının kaynak dokümana sadakati (Halüsinasyon oranı **<%2**).

8. Teknik Riskler ve Mühendislik Çözüm Stratejileri

Karşılaşılabilecek Saha Problemleri ve Mimari Önlemler

- **Risk 1: Gerçek Veri Bulma Zorluğu (Cold Start & Gizlilik):** Holdingler gerçek finansal/sözleşme verilerini NDA (Gizlilik Sözleşmesi) olmadan paylaşmakta çekimser kalabilir.
  Çözüm: Kurumlardan sadece *boş doküman şablonları* ve *veri şemaları* istenecek; bu şablonlar üzerinden LLM ile gerçeğe birebir benzeyen zengin bir **Sentetik Veri Seti (Synthetic Holding Dataset)** üretilerek geliştirme aşaması bloklanmadan yürütülecektir.
- **Risk 2: Bozuk Taranmış PDF'ler ve Karmaşık Tablolar:** Silik mühürlü, eğik taranmış veya sayfalar arası bölünmüş tablolar standart OCR'ı bozar.
  Çözüm: Düz metin OCR yerine görsel-dil modelleri (**VLM - Qwen2.5-VL / Llama-3.2-Vision**) ve **Docling** kullanılarak sayfa doğrudan görsel olarak analiz edilecektir.
- **Risk 3: Text-to-SQL Güvenliği ve Hatalı Sorgular:** LLM'in yanlış JOIN yapması veya veritabanını kilitleyecek ağır sorgular üretmesi.
  Çözüm: LLM doğrudan ham Silver tablolarına değil, `dbt` ile önceden birleştirilmiş ve basitleştirilmiş **Gold View** katmanına sadece `READ-ONLY` yetkiyle sorgu atacaktır.

9. Saha Görüşmeleri İçin 3 Stratejik Soru (Requirement Engineering)

Holding ve banka yöneticileriyle yapılacak ilk toplantılarda projenin kapsamını (scope) netleştirecek şu üç soru yöneltilmelidir:

1. Kapsam Daraltma (Yüksek Etkili Use-Case Seçimi)

Soru: *"Şu an analistlerinizin her ay sonu yönetim raporu hazırlamak için manuel olarak açıp okuduğu, Excel'e kopyala-yapıştır yaptığı ve en çok vakit kaybettiği en kritik 2 doküman tipi nedir?"*
Stratejik Amaç: Sistemi tüm kurumsal belgelere uyarlamaya çalışmak yerine; örneğin sadece **Tedarikçi Sözleşmeleri ve Faturalar** veya **Denetim/Kredi Risk Raporları** üzerine odaklanarak bitirme projesi kapsamını gerçekçi tutmak.

2. Veri Gizliliği ve Kurulum Modeli (On-Premise vs. Cloud)

Soru: *"Anonimleştirilmiş verileri bulut tabanlı dış API'lere çıkarabiliyor muyuz, yoksa KVKK/BDDK regülasyonları gereği tamamen kurum içi sunucularda (On-Premise) çalışan açık kaynak modeller mi kurgulamalıyız?"*
Stratejik Amaç: Mimariyi yerel modellerle (`vLLM` üzerinde açık ağırlıklı LLM'ler) tamamen kapalı devre çalışacak şekilde sunarak kurumsal bilgi güvenliği bariyerini aşmak.

3. Veri Entegrasyonu ve Tekilleştirme Darboğazı

Soru: *"Farklı iştiraklerden gelen verileri konsolide ederken en büyük uyuşmazlık nerede yaşanıyor? Müşteri/tedarikçi unvanlarının farklı yazılması mı, hesap planı/ürün kodları mı, yoksa döviz ve tarih formatları mı?"*
Stratejik Amaç: Silver katmanında yazılacak veri temizleme (`dbt`) ve tekilleştirme (*Entity Resolution*) algoritmalarının kurallarını doğrudan gerçek saha problemine göre belirlemek.

10. 5 Kişilik Ekip İçin İş Paketleri (Work Packages)

Projenin modüler yapısı, 5 kişilik Bilkent CS ekibinin birbirini bloklamadan net arayüzlerle (API ve Veritabanı kontratlarıyla) paralel çalışmasına olanak tanır:

- **Üye 1 — Data Ingestion, Lakehouse Altyapısı & Güvenlik:** Dagster/Airflow iş akışları, MinIO (Bronze) kurulumu, PostgreSQL şema tasarımı, çok kiracılı yetkilendirme (Tenant/RLS) ve sentetik veri üretimi.
- **Üye 2 — Unstructured Data Parsing, VLM & OCR Hattı:** Docling ve PaddleOCR entegrasyonu, karmaşık PDF'lerden tablo ve sayfa koordinatlarının (`bounding_box`) çıkarılması, PII veri maskeleme.
- **Üye 3 — AI Bilgi Çıkarımı (LLM Extraction) & Entity Resolution (MDM):** Yerel LLM (Ollama/vLLM) kurulumu, Pydantic/Instructor ile JSON Schema zorlama, güven skoru hesaplama ve `Splink`/Embedding ile şirket/müşteri tekilleştirme.
- **Üye 4 — Data Modeling (dbt) & Hybrid RAG / Text-to-SQL Ajanı:** Silver'dan Gold katmanına geçiş için `dbt` dönüşüm modelleri, Qdrant vektör indeksleme ve LangGraph ile doğal dil sorgu yönlendiricisi (Router Agent).
- **Üye 5 — BI Entegrasyonu, HITL & Kullanıcı Arayüzü (Full-Stack):** Apache Superset dashboard entegrasyonu, düşük güven skorlu veriler için Human-in-the-Loop (İnsan Onayı + PDF üzerinde koordinat gösterimi) ekranı ve GenBI sohbet arayüzü (Next.js + FastAPI).